# SYS865 Inférence statistique avec programmation R

Ornwipa Thamsuwan

21 février 2024

#### SYS865 Inférence statistique avec programmation R

Ornwipa Thamsuwan

Recap

Puissance statistique

Détermination de la taille d'échantillon

D'autre option du logiciel : G\*Power

# Recap

#### SYS865 Inférence statistique avec programmation R

Ornwipa Thamsuwan

#### Recap

Puissance statistique

Détermination de la taille d'échantillon

D'autre option du logiciel : G\*Power

#### Ornwipa Thamsuwan

#### Recap

Puissance statistique

Détermination de la taille d'échantillon

D'autre option du logiciel : G\*Power

Travaux pratiques

► Objectifs de l'étude

► Formulation d'hypothèse

► Collecte des données : plan d'échantillonage

► Analyse des données : choix du test statistique

► Décision et interprétation

#### Recap

Détermination de la taille

D'autre option du logiciel: G\*Power

Travaux pratiques

Objectifs de l'étude

► Formulation d'hypothèse

► Collecte des données : plan d'échantillonage

► Analyse des données : choix du test statistique

Décision et interprétation

Comment choisir le test statistique ?

#### Les conditions pour les choix du test

► Test de normalité (Shapiro-Wilk)

SYS865 Inférence statistique avec programmation R

> Ornwipa Thamsuwan

Recap

uissance tatistique

Détermination de la taille d'échantillon

D'autre option du logiciel : G\*Power

#### Les conditions pour les choix du test

- ► Test de normalité (Shapiro-Wilk)
- ► Test de homogénéité des variances
  - ► Test F pour les données normalement distribuées
  - ► Test de Levene

SYS865 Inférence statistique avec programmation R

> Ornwipa Thamsuwan

Recap

Puissance statistique

Détermination de la taille d'échantillon

D'autre option du logiciel : G\*Power

#### SYS865 Inférence statistique avec programmation R

#### Les conditions pour les choix du test

- ► Test de normalité (Shapiro-Wilk)
- ► Test de homogénéité des variances
  - ► Test F pour les données normalement distribuées
  - ► Test de Levene

### Les paramètres à étudier

- La moyenne d'un échantillon ou la différence entre deux échantillons appariés
  - Test t avec paired=TRUE pour les données normalement distribuées
  - ► Test de Wilcoxon pour échantillons appariés

Ornwipa Thamsuwan

Recap

Puissance statistique

Détermination de la taille d'échantillon

D'autre option du logiciel : G\*Power

#### SYS865 Inférence statistique avec programmation R

### Les conditions pour les choix du test

- ► Test de normalité (Shapiro-Wilk)
- ► Test de homogénéité des variances
  - ► Test F pour les données normalement distribuées
  - ► Test de Levene

### Les paramètres à étudier

- ► La moyenne d'un échantillon ou la différence entre deux échantillons appariés
  - ► Test t avec paired=TRUE pour les données normalement distribuées
  - ► Test de Wilcoxon pour échantillons appariés
- Les moyennes des deux échantillons indépendants
  - Test t par défault pour les données normalement distribuées
  - ► Test de rang somme de Wilcoxon

Ornwipa Thamsuwan

#### Recap

uissance atistique

Détermination de la taille d'échantillon

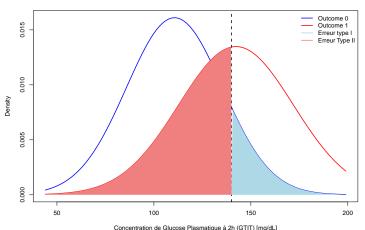
D'autre option du logiciel : G\*Power

# **Erreur statistique (retour)**

Erreur type I ( $\alpha$ ) : Rejeter  $H_0$  quand  $H_0$  est vraie.

Erreur type II  $(\beta)$ : Ne pas rejeter  $H_0$  quand  $H_0$  est fausse.

#### Normal Probability Distributions of Glucose by Outcome



SYS865 Inférence statistique avec programmation R

> Ornwipa Thamsuwan

Recap

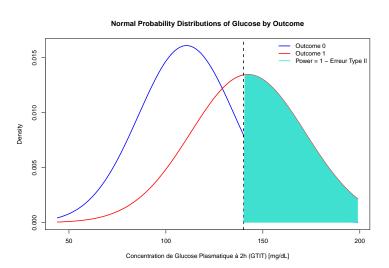
Puissance

Détermination de la taille d'échantillon

D'autre option du logiciel : G\*Power

# **Erreur statistique (retour)**

"Power"  $(1 - \beta)$ : Correctement rejeter  $H_0$  quand  $H_0$  est fausse, ou quand  $H_1$  est vraie.



SYS865 Inférence statistique avec programmation R

Ornwipa Thamsuwan

Recap

Puissance statistique

Détermination de la taille d'échantillon

D'autre option du logiciel : G\*Power

## Puissance statistique

SYS865 Inférence statistique avec programmation R

> Ornwipa Thamsuwan

Recap

Puissance statistique

Détermination de la taille d'échantillon

D'autre option du logiciel : G\*Power

Puissance statistique

Détermination de la taille d'échantillon

D'autre option du logiciel : G\*Power

		Reality	
		Positive	Negative
Study findings	Positive	True positive (Power) (1 – β)	False positive <b>Type I error</b> (α)
	Negative	False negative <b>Type II error</b> (β)	True negative

Figure 1: Tableau de contingence

Détermination de la taille d'échantillon

D'autre option du logiciel : G\*Power

- 1. Définir les hypothèses et décider du type de test t
- ▶ **Hypothèse nulle**  $(H_0)$ : Il n'existe aucune différence entre les groupes que vous comparez.
- **Hypothèse alternative**  $(H_1)$ : Il existe une différence significative.
- ▶ Décidez si l'on réalise un test t unilatéral (si l'on attend une différence dans une direction spécifique) ou bilatéral (en cas où les différences dans les deux directions sont pertinentes).

Détermination de la taille d'échantillon

D'autre option du logiciel : G\*Power

- 1. Définir les hypothèses et décider du type de test t
- ▶ **Hypothèse nulle**  $(H_0)$ : Il n'existe aucune différence entre les groupes que vous comparez.
- **Hypothèse alternative** ( $H_1$ ): Il existe une différence significative.
- ▶ Décidez si l'on réalise un test t unilatéral (si l'on attend une différence dans une direction spécifique) ou bilatéral (en cas où les différences dans les deux directions sont pertinentes).
- **2.** Choisir un niveau de signification ( $\alpha$ ). Typiquement,  $\alpha = 0.05$ .

- 1. Définir les hypothèses et décider du type de test t
- **Hypothèse nulle**  $(H_0)$ : Il n'existe aucune différence entre les groupes que vous comparez.
- **Hypothèse alternative** ( $H_1$ ): Il existe une différence significative.
- ▶ Décidez si l'on réalise un test t unilatéral (si l'on attend une différence dans une direction spécifique) ou bilatéral (en cas où les différences dans les deux directions sont pertinentes).
- **2.** Choisir un niveau de signification ( $\alpha$ ). Typiquement,  $\alpha = 0.05$ .
- 3. Supposer que la taille de l'échantillon (n) pour chaque groupe est donnée.

Détermination de la taille d'échaptillen

D'autre option du logiciel : G\*Power

Travaux pratiques

4. Déterminer la taille de l'effet

4. Determiner la taine de l'enet

La taille de l'effet de Cohen's d est définie comme:

$$d = \frac{\mu_1 - \mu_2}{SD_{\text{poolisée}}}$$

Où  $\mu_1$  et  $\mu_2$  sont les moyennes des deux groupes, et  $SD_{\text{poolisée}}$  est l'écart-type poolisé, calculé en fonction des écarts-types des deux groupes.

La taille de l'effet de Cohen's d est définie comme:

$$d = \frac{\mu_1 - \mu_2}{SD_{\text{poolisée}}}$$

Où  $\mu_1$  et  $\mu_2$  sont les moyennes des deux groupes, et  $SD_{\text{poolisée}}$  est l'écart-type poolisé, calculé en fonction des écarts-types des deux groupes.

$$SD_{\mathsf{poolis\acute{e}e}} = \sqrt{rac{(n_1 - 1) imes SD_1^2 + (n_2 - 1) imes SD_2^2}{n_1 + n_2 - 2}}$$

Où  $n_1$  et  $n_2$  sont les tailles d'échantillon des deux groupes, et  $SD_1$  et  $SD_2$  sont les déviations standard des deux groupes.

Ornwipa Thamsuwan

Recap

Puissance

statistique

Détermination de

D'autre option du

logiciel : G\*Power
Travaux pratiques

# Calcul de la puissance statistique

**5.** Calculer ou estimer la puissance  $(1 - \beta)$  avec R

SYS865 Inférence statistique avec programmation R

> Ornwipa Thamsuwan

Recap

Puissance statistique

Détermination de la taille d'échantillon

D'autre option du logiciel : G\*Power

Puissance statistique

Détermination de la taille

D'autre option du logiciel: G\*Power

Travaux pratiques

```
5. Calculer ou estimer la puissance (1 - \beta) avec R
```

**Paramètres** 

effect\_size <- 0.5 n1 < -30n2 < -40alpha <- 0.05

Paramètres

Calcul des degrés de liberté

## [1] 68

Ornwipa Thamsuwan

Recap

Puissance statistique

Détermination de la taille d'échantillon

D'autre option du logiciel : G\*Power

Iogiciel : G\*Power
Travaux pratiques

Puissance statistique

Détermination de la taille

D'autre option du logiciel : G\*Power

Travaux pratiques

```
Calcul de la valeur t critique
```

```
t_critical <- qt(1 - alpha / 2, df)
t_critical</pre>
```

```
## [1] 1.995469
```

La fonction qt() fournit le quantile de la distribution t.

Puissance

logiciel: G\*Power

Calcul du paramètre de non-centralité

 $ncp \leftarrow effect size * sqrt((n1 * n2) / (n1 + n2))$ 

ncp

## [1] 2.070197

Le paramètre de non-centralité ncp représente à quel point l'effet réel est éloigné de l'hypothèse nulle dans le contexte d'une hypothèse alternative spécifique.

Le ncp est ajusté pour les tailles d'échantillon inégales en utilisant la formule suivante :

$$ncp = ext{effect size} imes \sqrt{rac{n_1 imes n_2}{n_1 + n_2}}$$

D'autre option du logiciel : G\*Power

Travaux pratiques

Calcul de la puissance

power <- 1 - pt(t\_critical, df, ncp)
power</pre>

## [1] 0.5322582

La fonction pt() donne la fonction de répartition (c'est-à-dire, la probabilité cumulée) pour la distribution t.

### **Facteurs importants**

#### Taille d'échantillon

```
n1 <- 120 # augmenté de 30
n2 <- 120 # augmenté de 40
```

SYS865 Inférence statistique avec programmation R

Ornwipa Thamsuwan

Recap

Puissance statistique

Détermination de la taille d'échantillon

D'autre option du logiciel : G\*Power

la taille

D'autre option du logiciel: G\*Power

n1 <- 120 # augmenté de 30 n2 <- 120 # augmenté de 40

Tout en fixant d'autres paramètres, la puissance augmente à

## [1] 0.9711088

Tout en fixant d'autres paramètres, la puissance augmente à

Taille d'effet

Ornwipa Thamsuwan

Recap

Puissance statistique

Détermination de la taille d'échantillon

D'autre option du logiciel : G\*Power

## **Facteurs** importants

#### SYS865 Inférence statistique avec programmation R

### Taille d'échantillon

Tout en fixant d'autres paramètres, la puissance augmente à

## [1] 0.9711088

## Taille d'effet

```
effect size <- 1 # augmenté de 0.5
```

Tout en fixant d'autres paramètres, la puissance augmente à

## [1] 0.9830511

Ornwina Thamsuwan

Puissance statistique

Détermination de

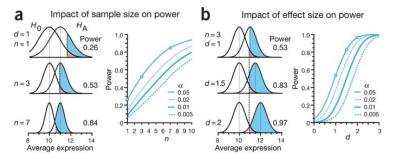
D'autre option du

logiciel: G\*Power

Détermination de la taille d'échantillon D'autre option du

logiciel : G\*Power

Travaux pratiques



**Figure 2:** Puissances statistiques sous différentes tailles d'effet et tailles d'échantillon

➤ **Référence**: Krzywinski, M., Altman, N. Power and sample size. *Nat Methods* **10**, 1139–1140 (2013). https://doi.org/10.1038/nmeth.2738

# Puissance statistique

SYS865 Inférence statistique avec programmation R

> Ornwipa Thamsuwan

Recap

Puissance statistique

Détermination de la taille d'échaptillen

D'autre option du logiciel : G\*Power

Travaux pratiques

Si nous n'avons pas encore collecté de données . . .

Et nous voulons connaître la taille de l'échantillon pour atteindre une puissance statistique prédéfinie . . .

# Détermination de la taille d'échantillon

#### SYS865 Inférence statistique avec programmation R

Ornwipa Thamsuwan

Recap

Puissance statistique

Détermination de la taille d'échantillon

D'autre option du logiciel : G\*Power

```
Fixer les paramètres suivants :
```

- ► Taille de l'effet (d de Cohen) : il s'agit de la différence anticipée entre les moyennes de deux groupes divisée par l'écart type.
- Niveau de signification  $\alpha = 0.05$ .
- Puissance souhaitée  $1 \beta = 0.80$ .

```
effect_size <- 0.5 # par ex. (mu1 - mu2) / sigma
alpha <- 0.05
power <- 0.80
```

Travaux pratiques

```
Fixer les paramètres suivants :
```

- ► Taille de l'effet (d de Cohen) : il s'agit de la différence anticipée entre les moyennes de deux groupes divisée par l'écart type.
- Niveau de signification  $\alpha = 0.05$ .
- Puissance souhaitée  $1 \beta = 0.80$ .

```
effect size <- 0.5 # par ex. (mu1 - mu2) / sigma
alpha <- 0.05
power <- 0.80
```

Trouver la **valeur t critique** pour le niveau de signification, puis utiliser la **distribution t non centrale** pour calculer la puissance.

```
calculate_sample_size <- function(d, power, alpha)</pre>
  n <- 2 # petit n sera incrémenté
  while(TRUE) {
    t crit \leftarrow qt(1 - alpha/2, df = 2*n - 2)
    ncp \leftarrow sqrt(n) * d
    beta \leftarrow pt(t_crit, df = 2*n - 2, ncp = ncp) -
             pt(-t crit, df = 2*n - 2, ncp = ncp)
    current power <- 1 - beta
    if (current_power >= power) {
      return(n)
    n < -n + 1
```

Ornwipa Thamsuwan

Rocan

Puissance statistique

Détermination de la taille d'échantillon

D'autre option du logiciel : G\*Power

Détermination de la taille d'échantillon

D'autre option du logiciel: G\*Power

Travaux pratiques

L'expression pt(t crit, df = 2\*n - 2, ncp = ncp)

calcule la probabilité (sous la distribution t non-centrale) d'observer une valeur t inférieure ou égale à t crit.

De même, pt(-t crit, df = 2\*n - 2, ncp = ncp) calcule la probabilité d'observer une valeur t inférieure ou égale à -t crit.

La différence entre ces deux probabilités (pt(t crit, df = 2\*n - 2, ncp = ncp) - pt(-t crit, df = 2\*n - 2, ncp = ncp)) donne essentiellement la probabilité d'une erreur de Type II ( $\beta$ ), qui est la probabilité de ne pas rejeter l'hypothèse nulle lorsque l'hypothèse alternative est vraie.

égale à -t crit.

Détermination de la taille d'échantillon

D'autre option du logiciel: G\*Power

Travaux pratiques

l'hypothèse nulle lorsque l'hypothèse alternative est vraie. calculate sample size(effect size, power, alpha)

L'expression pt(t crit, df = 2\*n - 2, ncp = ncp)

calcule la probabilité (sous la distribution t non-centrale) d'observer une valeur t inférieure ou égale à t crit.

De même, pt(-t crit, df = 2\*n - 2, ncp = ncp)

calcule la probabilité d'observer une valeur t inférieure ou

La différence entre ces deux probabilités (pt(t crit, df =

2\*n - 2, ncp = ncp) - pt(-t crit, df = 2\*n - 2, ncp = ncp)) donne essentiellement la probabilité d'une erreur de Type II ( $\beta$ ), qui est la probabilité de ne pas rejeter

## [1] 33

# Plus d'exemples

Utiliser le célèbre jeu de données iris, en nous concentrant sur les largeurs de sépales des espèces versicolor et virginica.

```
versicolor <-
   subset(iris, Species=="versicolor")$Sepal.Width
virginica <-
   subset(iris, Species=="virginica")$Sepal.Width</pre>
```



Figure 3: Iris dans une peinture de Vincent van Gogh

SYS865 Inférence statistique avec programmation R

> Ornwipa Thamsuwan

Recap

Puissance statistique

Détermination de la taille d'échantillon

D'autre option du logiciel : G\*Power

sample\_versicolor <- sample(versicolor, 5)</pre>

Prendre aléatoirement 5 points de données pour chacune des deux espèces (versicolor et virginica) dans la variable

d'échantillon

logiciel: G\*Power

Travaux pratiques

## [1] 2.4 2.9 2.9 3.1 3.0

Sepal.Width.

sample\_versicolor

```
sample virginica <- sample(virginica, 5)
sample virginica
```

```
## [1] 3.0 2.7 3.4 2.5 3.3
```

# Calculate effect size (Cohen's d)

```
# Calculate means and standard deviations
                                                                Thamsuwan
mean_versicolor <- mean(sample_versicolor)</pre>
mean_virginica <- mean(sample_virginica)</pre>
sd_versicolor <- sd(sample_versicolor)</pre>
sd_virginica <- sd(sample_virginica)</pre>
                                                              Détermination de
                                                              la taille
                                                              d'échantillon
                                                              D'autre option du
# Calculate pooled standard deviation
                                                              logiciel: G*Power
n <- 5 # sample size for each group
                                                               Travaux pratiques
pooled sd <-
  sqrt(((n-1)*sd versicolor^2 +
            (n-1)*sd\_virginica^2) / (n+n-2)
```

effect\_size
## [1] -0.3618136

effect\_size <- (mean\_versicolor-mean\_virginica)/pooled\_sd

Puissance statistique

Détermination de la taille d'échantillon

D'autre option du logiciel : G\*Power

Travaux pratiques

```
# Calculate power using the effect size
alpha <- 0.05
t_critical <- qt(1 - alpha/2, df = 2*n - 2)
ncp <- effect_size * sqrt(n/2)
power <- 1 -
  pt(t_critical, df = 2*n - 2, ncp = ncp) +
  pt(-t_critical, df = 2*n - 2, ncp = ncp)
power</pre>
```

## [1] 0.0798854

Puissance statistique

Détermination de la taille d'échantillon

D'autre option du logiciel : G\*Power

Travaux pratiques

```
# Calculate power using the effect size
alpha <- 0.05
t_critical <- qt(1 - alpha/2, df = 2*n - 2)
ncp <- effect_size * sqrt(n/2)
power <- 1 -
  pt(t_critical, df = 2*n - 2, ncp = ncp) +
  pt(-t_critical, df = 2*n - 2, ncp = ncp)
power</pre>
```

## [1] 0.0798854

Quelle serait la taille minimale de l'échantillon afin d'avoir une puissance d'au moins 0,80 ?

```
Calcul de la puissance statistique (suite)
```

```
# Calculate power using the effect size alpha <- 0.05
```

```
t_critical <- qt(1 - alpha/2, df = 2*n - 2)
ncp <- effect_size * sqrt(n/2)
power <- 1 -
  pt(t_critical, df = 2*n - 2, ncp = ncp) +
  pt(-t_critical, df = 2*n - 2, ncp = ncp)
power</pre>
```

```
## [1] 0.0798854
```

Quelle serait la taille minimale de l'échantillon afin d'avoir une puissance d'au moins 0,80 ?

```
desired_power <- 0.80
calculate_sample_size(effect_size, desired_power, alpha)</pre>
```

Détermination de la taille

d'échantillon
D'autre option du logiciel : G\*Power
Travaux pratiques

SYS865 Inférence statistique avec programmation R

Thamsuwan

41 / 46

### Détermination de la taille d'échantillon

SYS865 Inférence statistique avec programmation R

> Ornwipa Thamsuwan

Recap

Puissance statistique

Détermination de la taille d'échantillon

D'autre option du logiciel : G\*Power

Travaux pratiques

"The larger sample size, the more confidence you can be that your sample mean is a good representation of your population mean.

In other words, the N justifies the means."

D'autre option du logiciel : G\*Power

SYS865 Inférence statistique avec programmation R

> Ornwipa Thamsuwan

Recap

Puissance statistique

Détermination de la taille d'échantillon

D'autre option du logiciel : G\*Power

# D'autre option du logiciel : G\*Power



Ornwipa Thamsuwan

Recap

Puissance statistique

Détermination de la taille d'échantillon

D'autre option du logiciel : G\*Power

Travaux pratiques



**Figure 4:** G\*Power

### Lien pour le télécharger :

https://www.psychologie.hhu.de/arbeitsgruppen/allgemeine-psychologie-und-arbeitspsychologie/gpower

En tous cas, en utilisant G\*Power, il faut comprendre et précalculer le paramètre de noncentralité 'ncp' (ou la notion de taille d'effet).

# **Travaux pratiques**

SYS865 Inférence statistique avec programmation R

> Ornwipa Thamsuwan

Recap

Puissance statistique

Détermination de la taille d'échantillon

D'autre option du logiciel : G\*Power

Puissance statistique

Détermination de la taille d'échantillon

D'autre option du logiciel : G\*Power

Travaux pratiques

A partir de la base de données "Pima Indian Diabetes", supposant que  $\alpha=0.05$  pour chacun des huit paramètres (Pregnancies, Glucose, BloodPressure, SkinThickness, Insulin, BMI, DiabetesPedigreeFunction et Age) ...

- 1. Calculer la puissance statistique  $(1 \beta)$  pour détecter la différence entre les deux groupes de Outcome
- **2.** Calculer la taille minimale de l'échantillon afin d'avoir une puissance statistique d'au moins 0,80

Essayez d'utiliser à la fois R et G\*Power.